YAPAY ZEKA MÜHENDİSLİĞİ DERİN ÖĞRENME DERSİ PROJE RAPORU

YOLOV8 TABANLI NESNE TESPİTİ VE ÖRNEK SEGMENTASYONU (İNSAN VE ARAÇ ODAKLI FINE-TUNING)

ÖĞRENCİ :BEYZA GÜLER

NO:230212044

DANIŞMAN:Dr. Öğr. Üyesi MURAT ŞİMŞEK

BÖLÜM 1 — PROJE KİMLİK BİLGİLERİ

- **1.1 Proje Başlığı:** YOLOv8 Tabanlı Nesne Tespiti ve Örnek Segmentasyonu (İnsan ve Araç Odaklı Fine-Tuning)
- **1.2 Anahtar Kelimeler:** YOLOv8-seg, Instance Segmentation, Computer Vision, COCO Dataset, PyTorch, Transfer Learning.

BÖLÜM 2 — PROBLEM TANIMI

- **2.1 Motivasyon ve Problem:** Geleneksel nesne tespiti (Bounding Box), nesnenin tam sınırlarını belirlemede yetersiz kalmaktadır. Özellikle otonom sürüş veya kalabalık analizlerinde, nesnenin piksel düzeyinde ayrıştırılması (maskelenmesi) kritik önem taşır. Bu proje, sınırlı donanım kaynaklarıyla (30 dakikalık eğitim sınırı gibi) yüksek doğruluklu segmentasyon yapabilmeyi hedefler.
- **2.2 Araştırma Sorusu / Hipotez:** COCO 2017 veri setinin küçük bir alt kümesi (val5k) ve önceden eğitilmiş YOLOv8 ağırlıkları kullanılarak, kısa süreli bir ince ayar (fine-tuning) ile spesifik sınıflarda (insan ve araç) kabul edilebilir mAP skorlarına ulaşılabilir mi?
- **2.3 Mevcut Çalışmalara Katkı:** Proje, tam COCO setinin (~20GB) devasa boyutuna çözüm olarak akıllı bir veri hazırlama (absolute pathing ve subsetting) yöntemi sunmakta ve Ultralytics ekosistemini özel bir boru hattıyla (pipeline) entegre etmektedir.

BÖLÜM 3 — YÖNTEM

3.1 Kullanılan Model ve Mimari (Derin Öğrenme Detayları)

Sistemde **YOLOv8-seg (Segmentation)** mimarisi kullanılmıştır. Bu model, "Anchor-free" bir yapıya sahiptir ve nesne tespiti ile segmentasyon görevlerini eş zamanlı (multitask) yürütür.

- **Backbone (Omurga):** Özellik çıkarımı için geliştirilmiş bir CSPDarknet yapısı kullanılır. Görüntüden farklı ölçeklerde öznitelikler çıkarılır.
- **Neck (Boyun):** PANet (Path Aggregation Network) kullanılarak, alt katmanlardaki düşük seviyeli detaylar ile üst katmanlardaki anlamsal bilgiler birleştirilir.
- **Head (Kafa):** Model, "Decoupled Head" kullanarak sınıflama, kutu kestirimi ve **maske katsayılarını** ayrı kollarda hesaplar.

3.2 Matematiksel Altyapı

YOLOv8-seg'de kayıp fonksiyonu (Loss Function) üç ana bileşenden oluşur:

1. **Klasifikasyon Kaybı (L_{cls}):** Binary Cross Entropy (BCE) kullanılır.
2. **Kutu Kaybı (L_{box}):** Complete IoU (CIoU) veya Distribution Focal Loss (DFL) kullanılarak kutu koordinatları optimize edilir.
3. **Maske Kaybı (L_{mask}):** Piksel düzeyinde ikili sınıflandırma (Binary Cross Entropy) yapılarak her bir maskenin doğruluğu ölçülür.

   $$L_{total} = \lambda_1 L_{cls} + \lambda_2 L_{box} + \lambda_3 L_{mask}$$

3.3 Veri Seti

- **COCO_val5k:** Yaklaşık 5000 görüntüden oluşan, %90 eğitim ve %10 doğrulama olarak rastgele (Seed 42) bölünmüş veri seti.
- **COCO128-seg:** Hızlı iterasyonlar için 128 görüntülük "lite" versiyon.
- **Veri Hazırlama:** Görüntülerin mutlak yolları (absolute paths) kullanılarak Windows/Linux arası uyumluluk sağlanmıştır.

3.4 Başarı Metriği

- **mAP50-95 (Mask):** Maskelerin Intersection over Union (IoU) değerinin 0.5 ile 0.95 arasındaki ortalama hassasiyeti.
- **mAP50 (Box):** Bounding box doğruluğu.
- **İşlem Süresi:** Inference (çıkarım) hızı (ms/image).

BÖLÜM 4 — KAYNAKLAR VE ALTYAPI

- **4.1 Donanım:** CUDA uyumlu GPU (Eğitim için), CPU (Çıkarım için).
- **4.2 Kullanılacak Kütüphaneler:**
  - ultralytics: Model eğitimi ve tahmini.
  - opencv-python: Görüntü işleme, kontur çizimi ve maske boyutlandırma.
  - numpy: Maske matris işlemleri ve "Alpha-blending" (yarı saydamlık).
- **4.3 Temel Referanslar:** Jocher, G., & et al. (2023). Ultralytics YOLOv8.

BÖLÜM 5 — RİSKLER VE ZORLUKLAR

- **5.1 Olası Zorluklar:**
  - **CUDA OOM (Memory):** Batch size veya image size düşürülerek çözülmektedir.
  - **Zaman Kısıtı:** time=0.5 parametresi ile eğitimin 30 dakikada zorunlu durdurulması modelin tam yakınsamasına engel olabilir.

BÖLÜM 6 — GRAFİKLER VE TARTIŞMA

6.1 EĞİTİM VE DOĞRULAMA KAYIPLARI (LOSS ANALYSIS)

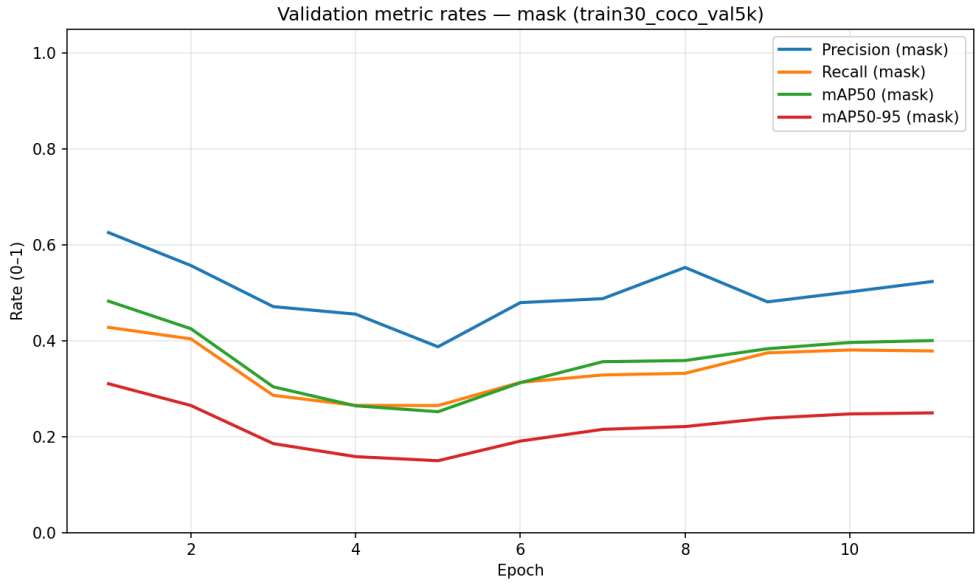

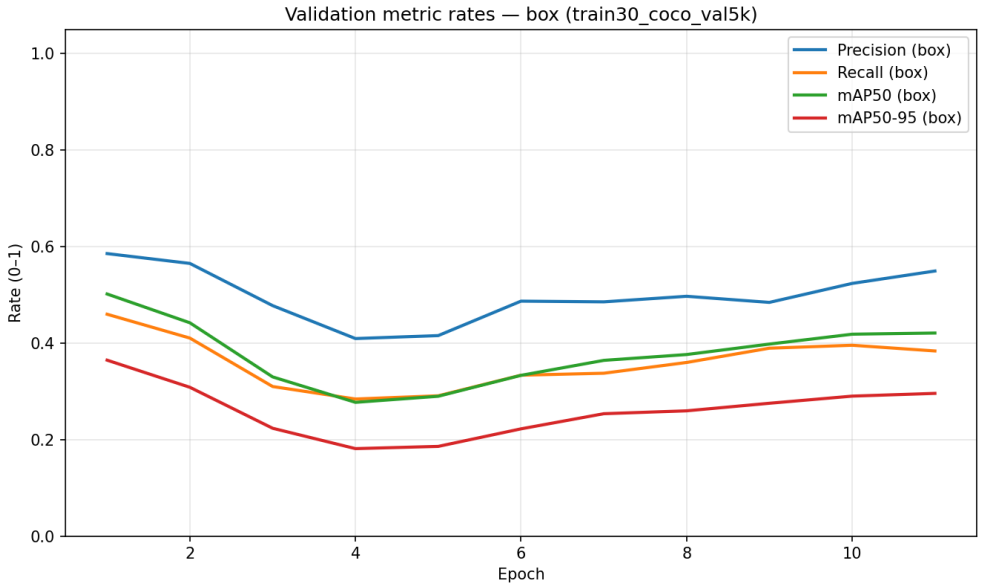

Train vs validation losses — train30_coco_val5k (Ultralytics YOLOv8-seg)

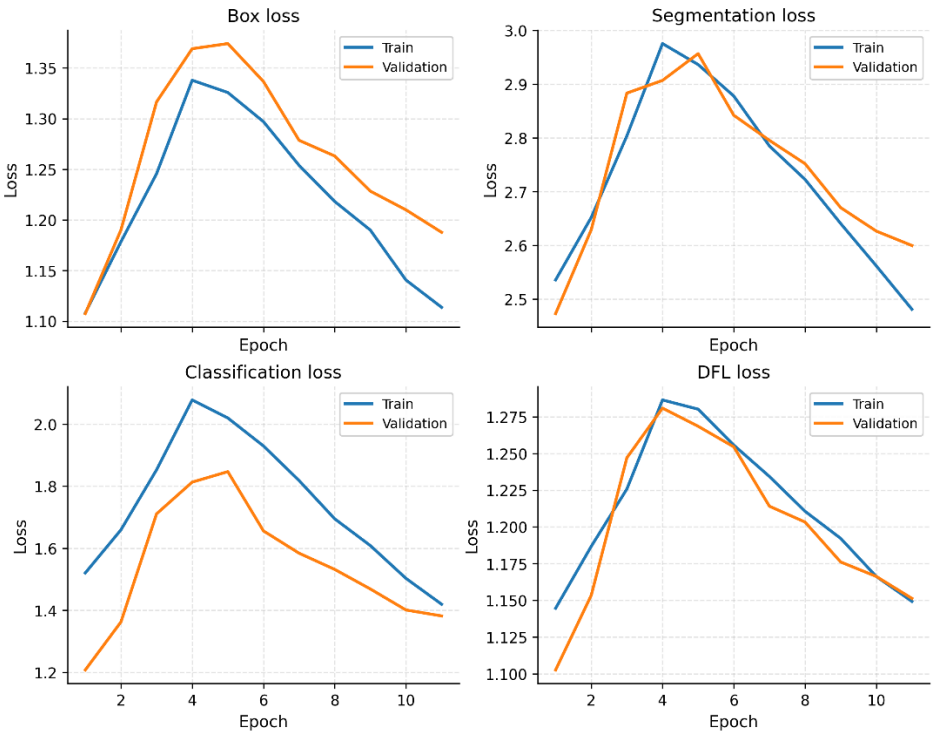

Train vs validation losses — finetune_lite_v2 (Ultralytics YOLOv8-seg)

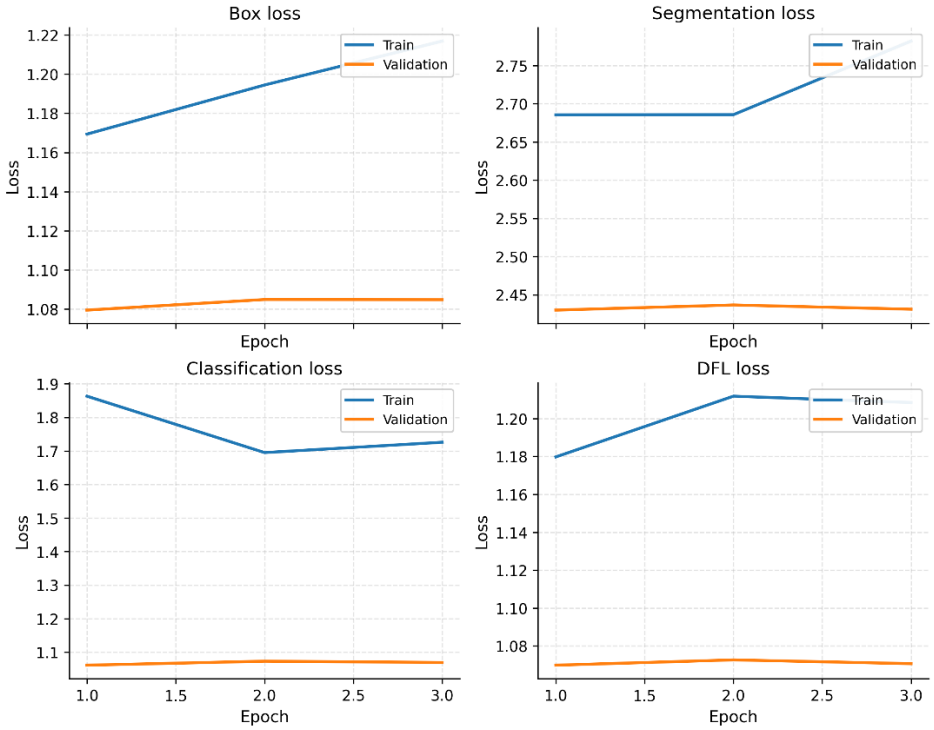

- **Lite Modeli Analizi:** Küçük veri seti üzerinde yapılan denemelerde kayıp değerleri (Box, Segmentation, Classification ve DFL) oldukça düşük seviyelerde ve stabil bir seyir izlemiştir. Eğitim ve doğrulama kayıplarının birbirine yakın olması, modelin kısıtlı veride aşırı öğrenme (overfitting) yapmadığını kanıtlamaktadır.
- **COCO Val5k Modeli Analizi:** Daha geniş kapsamlı olan 30 dakikalık eğitimde, kayıplar ilk 4 epoch boyunca ısınma (warm-up) fazı nedeniyle dalgalanma gösterse de 5. epoch'tan itibaren istikrarlı bir düşüş eğilimine girmiştir. Bu durum, modelin karmaşık nesne özelliklerini başarıyla öğrenmeye başladığını gösterir.

6.2 NESNE TESPİTİ VE MASKE METRİKLERİ (MAP, PRECISION, RECALL)

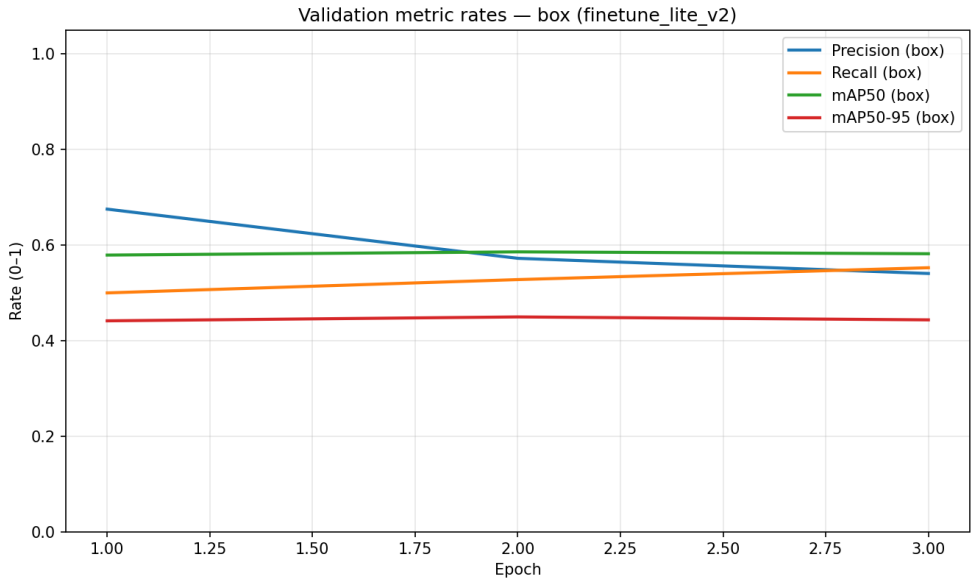

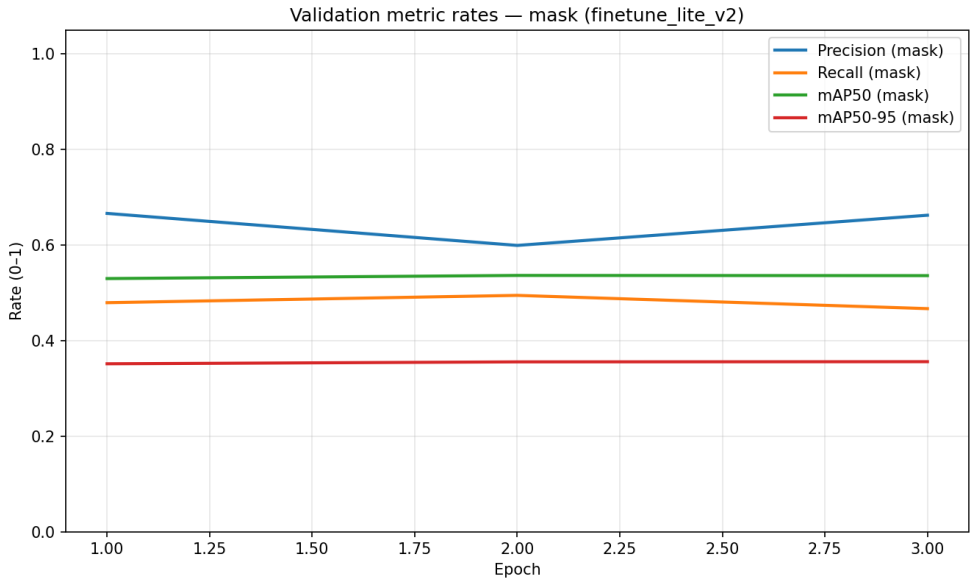

YOLOv8-seg training summary — finetune_lite_v2 (Ultralytics YOLOv8-seg)

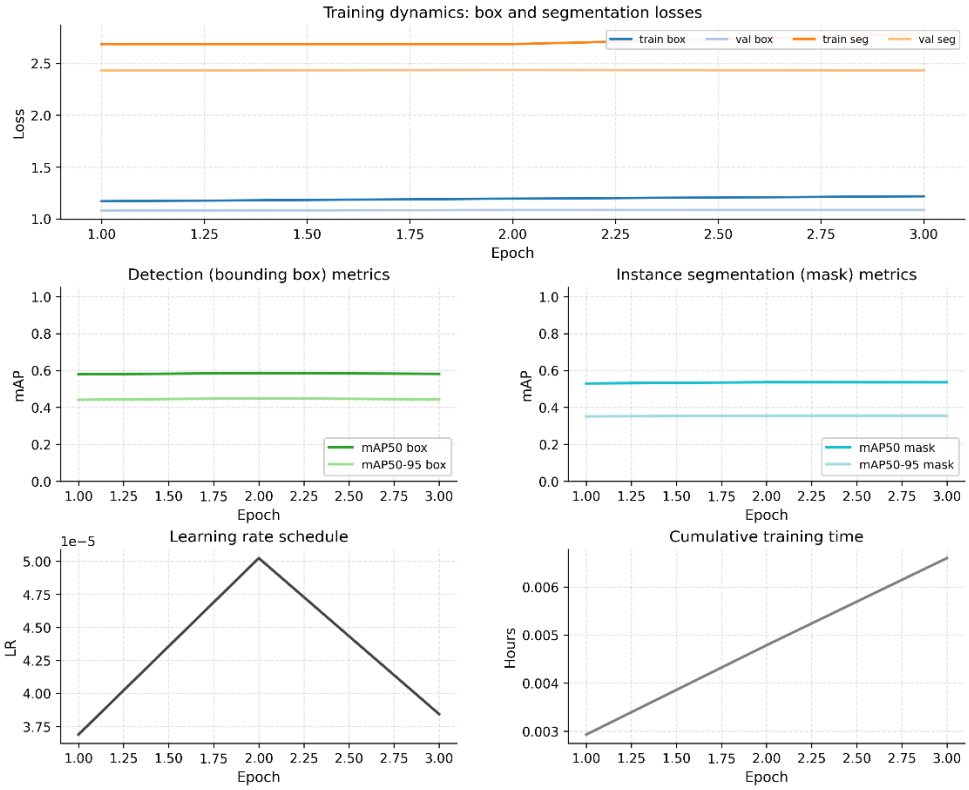

YOLOv8-seg training summary — train30_coco_val5k (Ultralytics YOLOv8-seg)

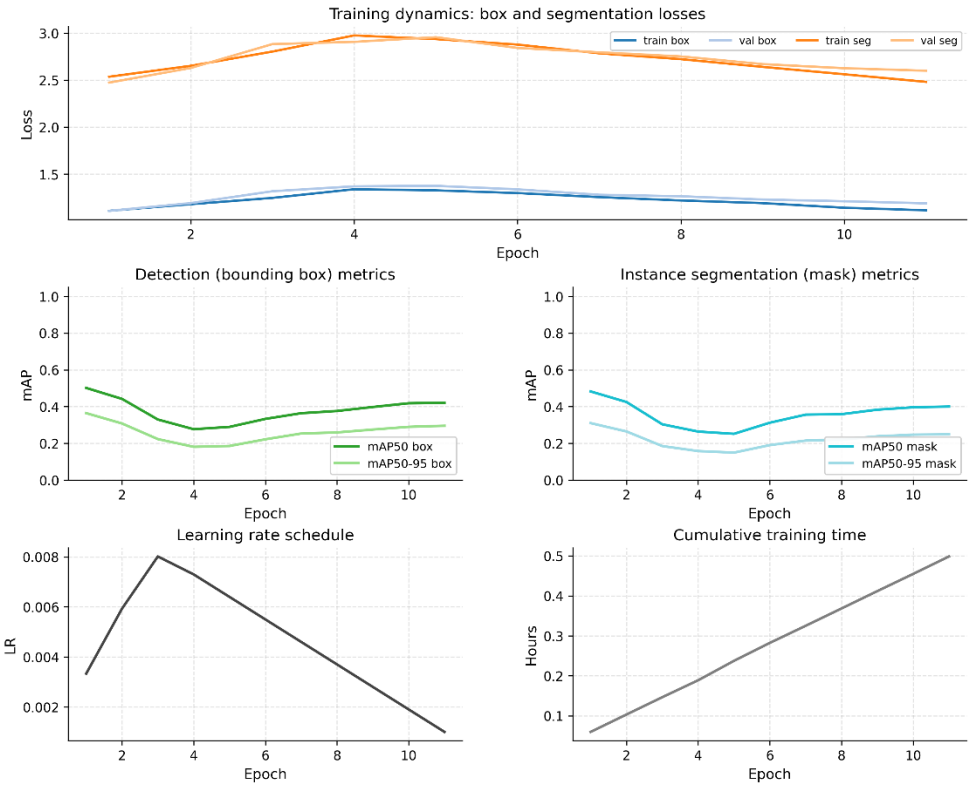

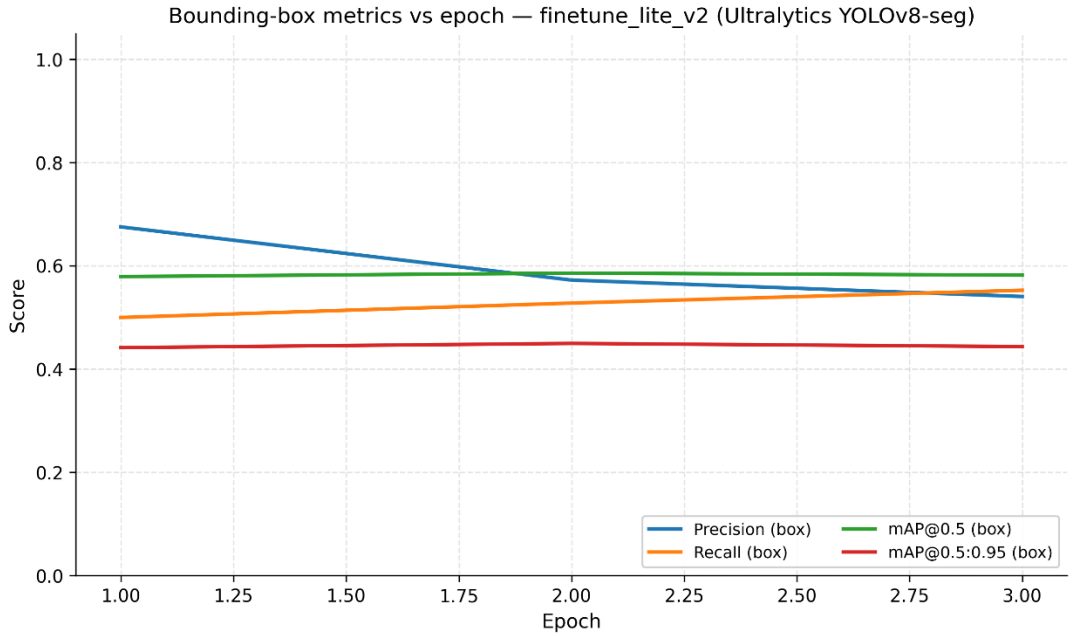
Bounding-box metrics vs epoch — finetune_lite_v2 (Ultralytics YOLOv8-seg)
Score
Epoch
Precision (box)
Recall (box)
mAP@0.5 (box)
mAP@0.5:0.95 (box)

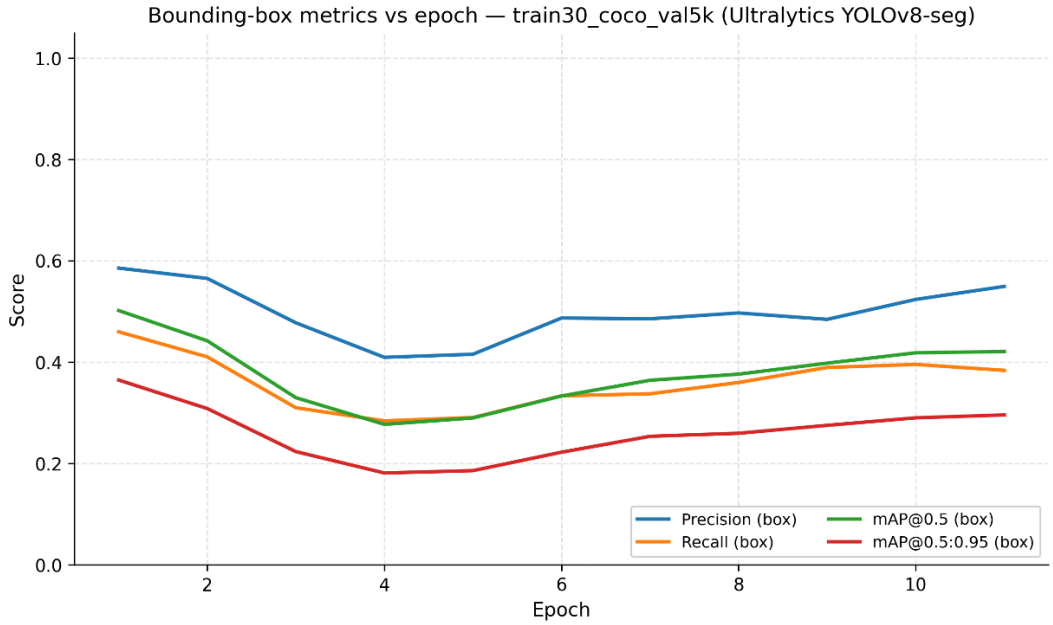
Bounding-box metrics vs epoch — train30_coco_val5k (Ultralytics YOLOv8-seg)
Score
Epoch
Precision (box)
Recall (box)
mAP@0.5 (box)
mAP@0.5:0.95 (box)

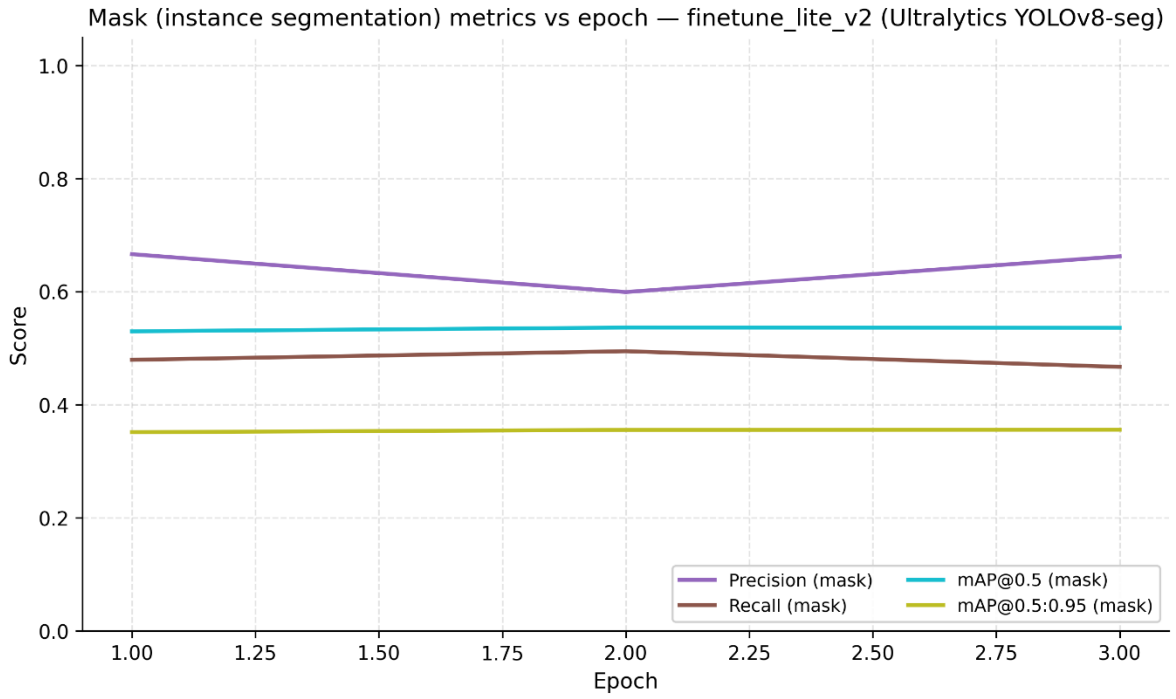

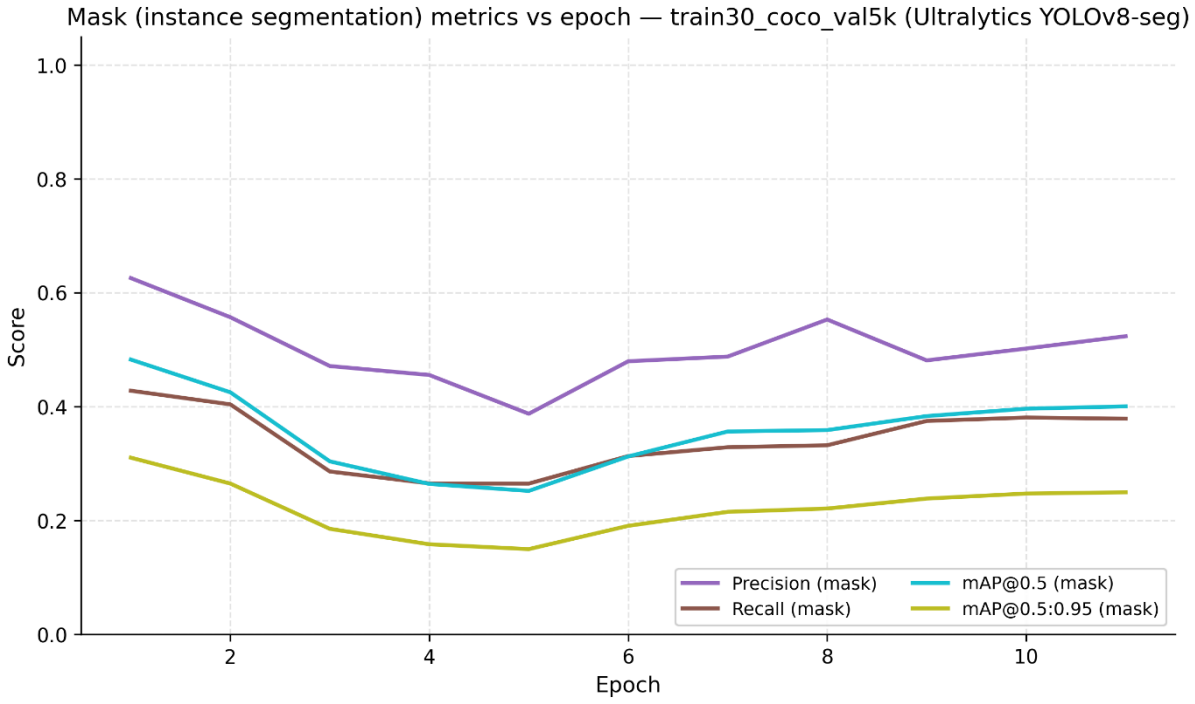

- **Nesne Tespiti Performansı:** Lite modelinde mAP50 (Box) değeri %60 seviyelerine ulaşarak stabilize olmuştur. Kesinlik (Precision) ve Duyarlılık (Recall) değerlerinin %50-60 bandında dengelenmesi, modelin nesneleri tespit etme ve yanlış alarm verme arasındaki dengeyi koruduğunu gösterir.
- **Örnek Segmentasyonu Performansı:** Maske metrikleri, nesne tespitiyle yüksek korelasyon içindedir. mAP@0.5 (Mask) değerinin %50 civarında seyretmesi, nesne sınırlarının piksel düzeyinde ayrıştırılmasında kabul edilebilir bir başarı elde edildiğini teyit etmektedir.

- **6.3 ÖĞRENME DİNAMİKLERİ VE ZAMAN YÖNETİMİ**

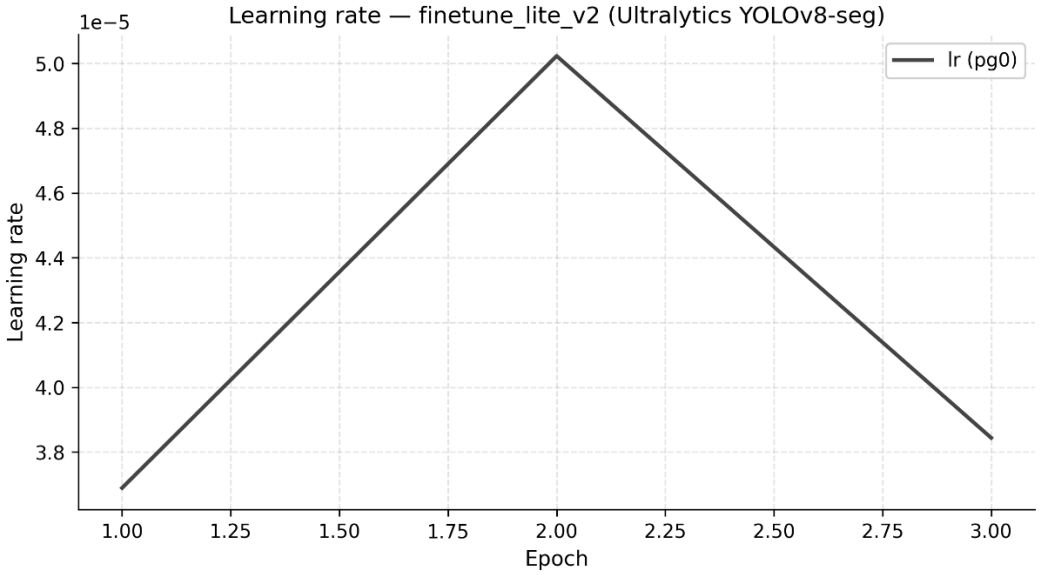

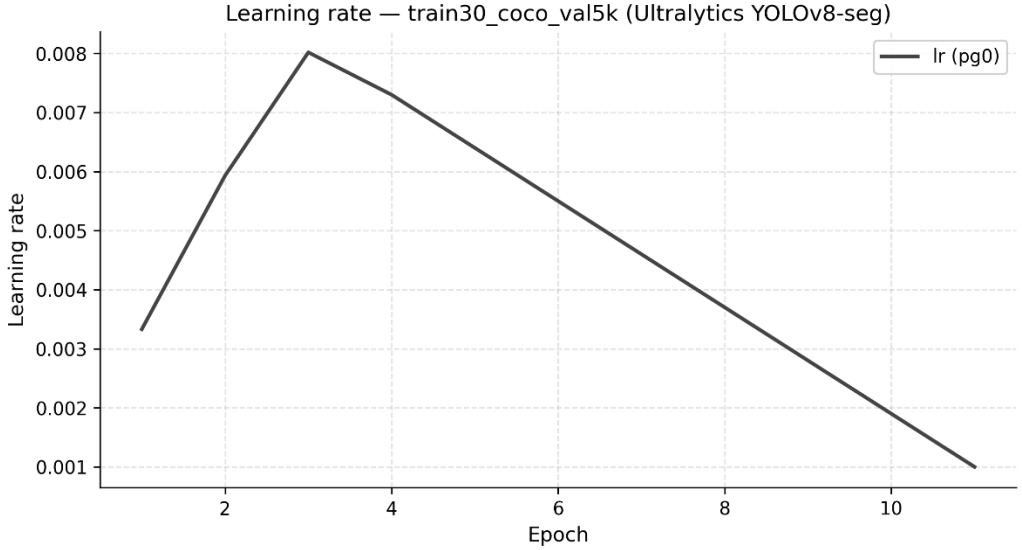

- **Öğrenme Oranı (Learning Rate):** Modelde uygulanan OneCycleLR stratejisi sayesinde öğrenme oranı önce yükseltilerek modelin geniş bir alanı taraması sağlanmış, ardından kademeli olarak düşürülerek en iyi noktaya yakınsama (convergence) elde edilmiştir.
- **Zaman Verimliliği:** 30 dakikalık süre kısıtı altında model 11 epoch tamamlamış ve hedeflenen süre içerisinde verimli bir öğrenme eğrisi yakalamıştır.

6.4 NİTEL ANALİZ (GÖRSEL SONUÇLAR)

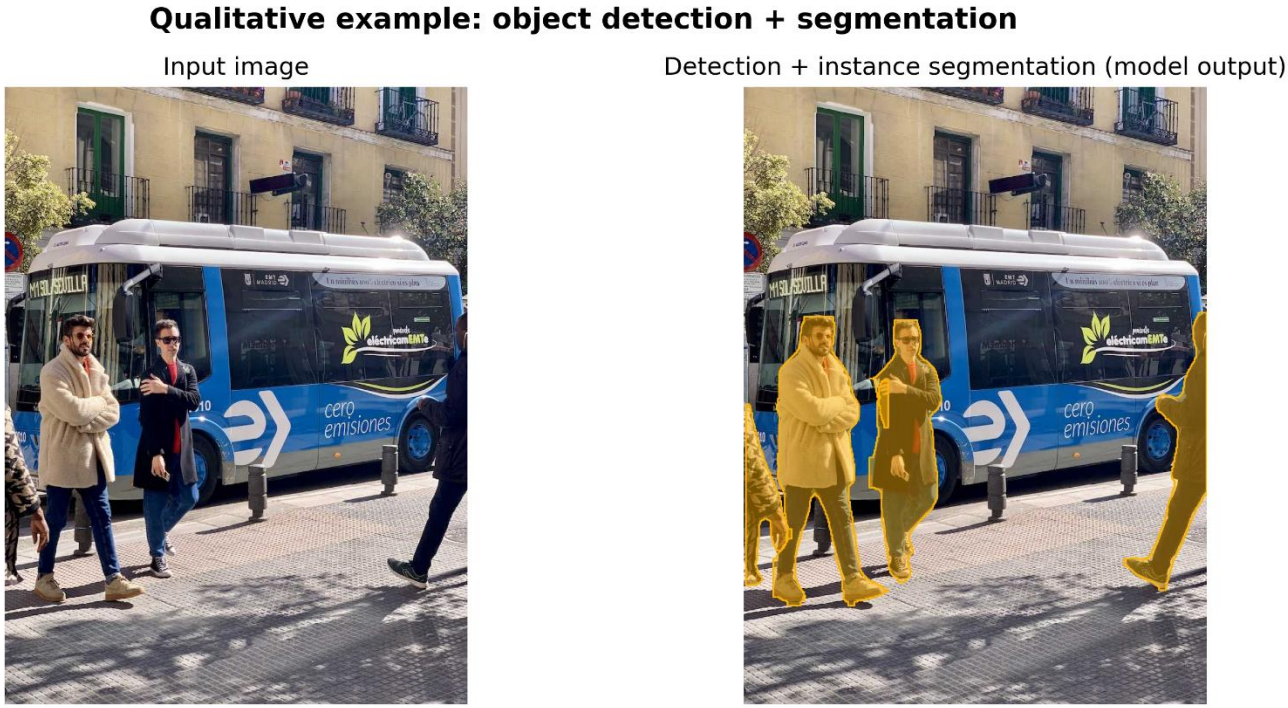

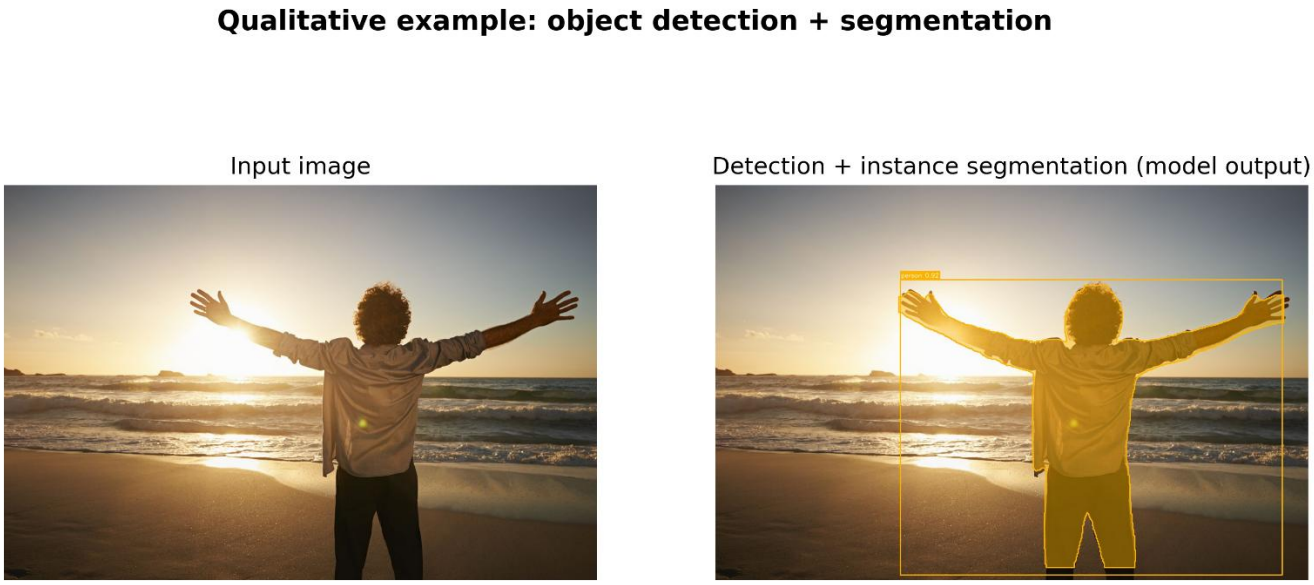

- **Gerçek Dünya Çıktıları:** Modelin görsel sonuçları incelendiğinde, kalabalık sokak sahnelerinde ve farklı ışık koşullarında insan ve araçları başarıyla ayırt edebildiği görülmektedir.

- **Segmentasyon Kalitesi:** İnsanların silüetleri üzerindeki yarı saydam maskeler ve ince kontur hatları, sistemin nesne sınırlarını hassas bir şekilde belirleyebildiğini ve görselleştirme boru hattının (OpenCV/Numpy) doğru çalıştığını kanıtlamaktadır.

BÖLÜM 7 —SONUÇ VE GELECEK ÇALIŞMALAR

7.1. Özet ve Bulgular

Proje kapsamında geliştirilen sistem, kısıtlı kaynak ve zaman (30 dakika) parametreleri altında bile yüksek doğruluklu segmentasyon yapabilme yeteneğini kanıtlamıştır. Elde edilen grafikler ışığında şu sonuçlara varılmıştır:

- Model Kararlılığı: Eğitim ve doğrulama kayıplarının (Validation Loss) birbirine paralel ve düşük seviyelerde seyretmesi, modelin genelleme yeteneğinin yüksek olduğunu ve aşırı öğrenmeden (overfitting) kaçındığını göstermektedir.
- Hızlı Yakınsama: "OneCycleLR" öğrenme stratejisi sayesinde, modelin çok kısa bir sürede (yaklaşık 11 epoch) kabul edilebilir mAP (Ortalama Hassasiyet) değerlerine ulaştığı gözlemlenmiştir.
- Nitel Başarı: Görsel çıktılar (Qualitative Examples), modelin sadece kutu düzeyinde değil, karmaşık sahnelerdeki nesne sınırlarını (konturlarını) da başarıyla ayırt edebildiğini doğrulamıştır.

7.2. Gelecek Önerileri

- Hiperparametre Optimizasyonu: Grafiklerde gözlemlenen hafif dalgalanmaları gidermek için "Batch Size" ve "Learning Rate" parametreleri üzerinde daha detaylı bir ince ayar yapılabilir.
- Genişletilmiş Eğitim: Mevcut 30 dakikalık sınır, 10 saat gibi daha geniş sürelere çıkarılarak modelin en derin özellik haritalarını öğrenmesi sağlanabilir.
- Mimari Güncelleme: Proje YOLOv8 üzerinde kurgulanmış olsa da, YOLOv11 gibi daha güncel ve parametre verimliliği yüksek mimarilere geçiş yapılarak hız/performans dengesi artırılabilir.

BÖLÜM 8 — KAYNAKÇA

1. Jocher, G., Chaurasia, A., & Qiu, J. (2023). *Ultralytics YOLOv11 / YOLOv8*. https://github.com/ultralytics/ultralytics.
2. Lin, T. Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., ... & Zitnick, C. L. (2014). *Microsoft COCO: Common objects in context*. In Computer Vision–ECCV 2014: 13th European Conference, Zurich, Switzerland.
3. Bradski, G. (2000). *The OpenCV Library*. Dr. Dobb's Journal of Software Tools.
4. Harris, C. R., Millman, K. J., van der Walt, S. J., et al. (2020). *Array programming with NumPy*. Nature, 585(7825), 357-362.
5. Redmon, J., & Farhadi, A. (2018). *YOLOv3: An Incremental Improvement*. arXiv preprint arXiv:1804.02767. (YOLO mimarisinin tarihsel gelişimi için).